

Estudo de Ablação da LightCNN

Introdução à Aprendizagem Profunda - Estudo de Ablação

Componente avaliado: Batch Normalization

PyTorch 2.11.0 + CUDA | NVIDIA GeForce RTX 4050 Laptop GPU

1. Objetivo

Este estudo avalia o impacto da Batch Normalization na CNN customizada LightCNN. Foram comparadas duas versões do mesmo modelo: uma com BatchNorm, equivalente à arquitetura original da APS anterior, e outra sem as camadas BatchNorm2d.

2. Metodologia


A arquitetura base possui três blocos convolucionais seguidos por um classificador: Conv2d -> BatchNorm opcional -> ReLU -> MaxPool. O restante da arquitetura foi mantido igual nas duas variantes.

Dataset	Épocas	Batch size	Otimizador	Learning rate
MNIST	5	128	Adam	0,001
CIFAR-10	10	128	Adam	0,001

3. Resultados

3.1 MNIST


Variante	Parâmetros	Loss teste	Acurácia teste	Tempo
Com BatchNorm	390.858	0,0242	99,19%	241,5s
Sem BatchNorm	390.410	0,0182	99,40%	368,0s



No MNIST, a remoção da BatchNorm não prejudicou o desempenho. A versão sem BatchNorm alcançou acurácia ligeiramente maior, embora tenha levado mais tempo para treinar.


3.2 CIFAR-10

Variante	Parâmetros	Loss teste	Acurácia teste	Tempo
Com BatchNorm	620.810	0,7199	75,11%	272,8s
Sem BatchNorm	620.362	0,6740	76,71%	181,4s



No CIFAR-10, a versão sem BatchNorm também terminou com acurácia maior no recorte curto de 10 épocas. A curva com BatchNorm ainda mostra ganho rápido nas primeiras épocas, indicando possível estabilização inicial.

3.3 Comparação Final



Dataset	Melhor variante	Diferença de acurácia
MNIST	Sem BatchNorm	+0,21 ponto percentual
CIFAR-10	Sem BatchNorm	+1,60 ponto percentual

4. Discussão

O componente escolhido foi a Batch Normalization por estar presente em todos os blocos convolucionais da LightCNN original. Neste experimento enxuto, sua remoção não causou degradação de desempenho; pelo contrário, a versão sem BatchNorm foi ligeiramente melhor nos dois datasets.

Uma explicação possível é que a LightCNN é pequena, usa Adam como otimizador e mantém Dropout no classificador. Além disso, o estudo foi reduzido em número de épocas, o que pode favorecer variações de inicialização e ordem dos batches.

Portanto, o resultado não significa que BatchNorm seja inútil em geral, mas sim que ela não foi essencial para esta arquitetura e configuração específica.

5. Conclusão

A ablação mostrou que a Batch Normalization não foi indispensável para a LightCNN neste cenário. A versão sem BatchNorm alcançou 99,40% no MNIST e 76,71% no CIFAR-10, contra 99,19% e 75,11% da versão com BatchNorm.

Minha opinião é que, para esta CNN pequena e com treinamento curto, a BatchNorm pode ser removida sem perda de desempenho. Em redes maiores, treinamentos mais longos ou configurações mais instáveis, ela ainda pode ser útil.